

Les pipelines de génération augmentée par récupération dépendent d'un texte propre et bien segmenté. Lorsqu'un document source est un scan, aucune couche de texte natif n'existe : la compréhension visuelle devient la seule voie vers un contenu exploitable.

Cette page vérifie que le repli vision restitue des paragraphes lisibles à partir d'une image rastérisée. Le texte extrait doit préserver l'ordre de lecture et exclure les en-têtes et pieds de page qui n'appartiennent pas au corps.